Medición de la Similitud Semántica de Textos

Aroa Gómez Reta

3º GIA, UPV/EHU

1 Introducción

La Similitud Textual Semántica (STS) es una tarea fundamental en el Procesamiento del Lenguaje Natural (PLN) que consiste en medir el grado de equivalencia semántica entre dos fragmentos de texto. A diferencia de la similitud léxica, que simplemente compara palabras, la STS evalúa si dos textos transmiten el mismo significado. Esta capacidad es crucial para aplicaciones avanzadas como sistemas de búsqueda semántica, chatbots y sistemas de pregunta-respuesta.

El objetivo de este trabajo es explorar, implementar y evaluar sistemáticamente diferentes modelos para la tarea de STS. El proyecto se estructura en tres fases: (1) establecer bases de referencia (*baselines*) no supervisadas; (2) realizar un ajuste fino (*fine-tuning*) supervisado; y (3) evaluar la transferencia de conocimiento entre lenguas. En este informe se presentan los resultados obtenidos tras la experimentación de todas estas fases.

2 Trabajos Relacionados

La medición de similitud de texto ha evolucionado significativamente en los últimos años. Los métodos iniciales se basaban en la superposición léxica, como los n-gramas. Sin embargo, la llegada de las representaciones vectoriales *(embeddings)*, supuso un gran avance.

El desarrollo de los modelos Transformer y, en particular, de BERT, permitió crear *embeddings* contextuales, mucho más eficaces ya que "comprenden" el contexto, por lo que consiguen alcanzar unos resultados mucho mejores.Datos

3 Datos

3.1 Conjunto de Datos

Para este trabajo, se han utilizado dos conjuntos de datos disponibles en la plataforma Hugging Face. Estos son: el Conjunto STS Benchmark (en inglés) (/mteb/stsbenchmark-sts) para los objetivos Z1 y Z2, y su versión multilingüe (/stsb_multi_mt) para los experimentos de Z3.

Ambos datasets están divididos en ejemplos de train, validation y test, así que no ha sido necesario realizar una división de forma manual.

De cada instancia del dataset, la información utilizada ha sido: el par de oraciones a analizar (sentence1, sentence2) y su puntuación de similitud (score o similarity_score). Esta puntuación es un valor numérico en un rango de 0.0 (significado completamente diferente) a 5.0 (significado semánticamente equivalente). El análisis de las puntuaciones en el conjunto en inglés revela una media de 2.62.

3.2 Métrica de Evaluación

La métrica de evaluación principal es la Correlación de Pearson (pearsonr). Esta métrica mide la relación lineal entre las puntuaciones de similitud predichas por nuestros modelos y las puntuaciones humanas de referencia *(score o similarity score)*, arrojando un valor entre -1 y 1.

$$r = \frac{\sum(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum(x_i - \bar{x})^2 \sum(y_i - \bar{y})^2}}$$

Es la covarianza de las dos variables dividida por el producto de sus desviaciones estándar. Esto

normaliza el resultado para que siempre esté entre -1 y 1.

4 Sistemas utilizados

Para establecer una base de referencia, se han implementado dos sistemas no supervisados. Estos sistemas no utilizan las puntuaciones *(score o similarity score)* del conjunto de train para aprender; simplemente generan una puntuación de similitud basada en propiedades inherentes de las oraciones.

Ambos sistemas siguen una arquitectura **Bi-Encoder:** cada oración se procesa de forma independiente para generar una representación vectorial, y la similitud se calcula a posteriori, midiendo el coseno entre ambos vectores.

Después se han utilizado diferentes modelos Transformer preentrenados de tipo BERT, que consisten en ajustar de manera supervisada el modelo ya previamente entrenado para los datos a analizar. Estos siguen una arquitectura **Cross-Encoder:** las oraciones se procesan de manera conjunta mediante un mecanismo de atención.

4.1 Sistema 1: n-gramas

Este modelo representa las oraciones como vectores de "Bolsa de Palabras" (Bag-of-Words).

Se ha utilizado la herramienta *CountVectorizer* de la librería *scikit-learn*. Se ha configurado para extraer n-gramas de rango (1, 3), capturando así palabras individuales, bigramas y trigramas. La configuración que mejor ha funcionado ha sido la de los unigramas, ya que para el resto de n-gramas se necesita encontrar la misma secuencia de palabras en el mismo orden, por lo que nos encontramos con un problema de escasez *(sparsity)*.

El vectorizador ha ajustado (con el método *.fit()*) únicamente usando el conjunto de train. Posteriormente, las oraciones del conjunto de validación se han convertido en vectores numéricos (usando *.transform()*). La similitud entre frases se ha calculado usando la similitud del coseno.

4.2 Sistema 2: Sentence Embeddings

Este sistema utiliza un modelo especializado en generar *embeddings* de oraciones semánticamente significativos.

Se ha empleado la librería sentence-transformers para cargar el modelo pre-entrenado *sentence-transformers/all-MiniLM-L6-v2*. Este modelo codifica cada oración *(.encode())* en un *embedding* que representa su significado. La similitud entre frases se calcula usando la función *util.cos_sim* de la librería.

4.3 Sistema 3: Ajuste Fino de Modelos Transformer de tipo BERT

Este modelo procesa ambas oraciones simultáneamente dentro de la misma red y establece relaciones semánticas profundas entre pares de oraciones. Para ello, la entrada se estructura concatenando las dos oraciones separadas por un token especial (generalmente *[SEP]*), formando una única secuencia. Esto permite que el mecanismo de auto-atención *(self-attention)* del Transformer atienda a todos los tokens de ambas oraciones a la vez (atención cruzada), capturando matices y dependencias que se pierden al procesarlas por separado.

El proceso de ajuste fino *(fine-tuning)* consiste en entrenar el modelo pre-entrenado utilizando los pares de oraciones y sus etiquetas de similitud del conjunto de train. El entrenamiento busca minimizar la diferencia entre la predicción y la etiqueta real mediante una función de pérdida (como el Error Cuadrático Medio o MSE).

Para estos modelos se han realizado una serie de entrenamientos diferentes con diferentes datasets y varios experimentos para dar respuesta a una serie de hipótesis planteadas.

4.3.1 Entrenamiento inicial

Se han entrenado diferentes Transformers (distilBERT, BERT y xmlRoBERTa (multilingüe) con el dataset en inglés. Para ello se ha realizado una búsqueda en rejilla de hiperparámetros con el fin de encontrar el mejor modelo.

4.3.2 Transferencia entre Lenguas

Posteriormente se han analizado los modelos entrenados en inglés con el dataset en castellano, para ver si alguno de ellos arrojaba resultados aceptables (*zero-shot transfer*).

Se ha entrenado el modelo multilingüe en castellano (entrenamiento navito). También se ha entrenado secuencialmente el modelo ya entrenado en inglés en castellano (*fine-tuning* secuencial). Así se han comparado ambos resultados para comprobar si la transferencia entre lenguas es útil (lo es si los resultados son mejores utilizando el modelo entrenado secuencialmente que el modelo entrenado únicamente en castellano).

Por último, se han realizado otros dos experimentos: entrenar el modelo secuencialmente en inglés, italiano y castellano para comprobar la hipótesis que plantea que a mayor número de lenguas de entrenamiento mejores serán los resultados para una de esas lenguas. Y, por otro lado, juntar los datasets y posteriormente realizar el entrenamiento con el dataset ya unido, en lugar de hacer un entrenamiento secuencial, para analizar cómo aprende el modelo en este caso.

5 Resultados y Análisis

La evaluación de los sistemas se ha realizado comparando sus predicciones con las puntuaciones de referencia del conjunto de validación.

5.1 Z1 y Z2: dataset en inglés

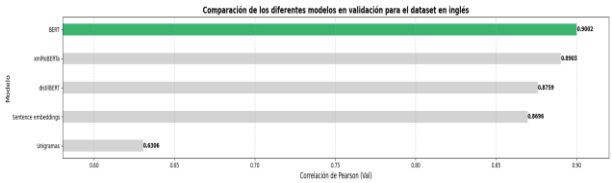

Como se puede observar en la gráfica de comparación de los modelos empleados, se observa una clara progresión en el rendimiento a medida que aumenta la complejidad y la capacidad semántica de los modelos utilizados. La gráfica muestra la siguiente evolución:

- Unigramas: Obtienen el desempeño más bajo, situándose en una correlación de 0.63. Este resultado confirma las limitaciones del enfoque léxico (*Bag-of-Words*). Al basarse únicamente en la coincidencia exacta de palabras, el modelo no logra capturar similitudes semánticas cuando se utilizan sinónimos o estructuras gramaticales diferentes, lo que penaliza fuertemente su puntuación en comparación con el resto de modelos.
- Sentence Embeddings: Se produce un salto cualitativo muy significativo respecto a los n-gramas. Con un 0.86 de correlación, este sistema demuestra la eficacia de los *embeddings* densos. El modelo es capaz de entender que dos frases tienen significados cercanos, aunque no compartan las mismas palabras, gracias a su entrenamiento previo en grandes corpus semánticos.
- Modelos Transformer tipo BERT: Los modelos basados en la arquitectura *Cross-Encoder* y ajustados mediante *fine-tuning* alcanzan los mejores resultados (correlaciones entre 0.87 y 0.90), superando ligeramente al *Bi-Encoder* (*embeddings*). Dentro de esta categoría se han comparado tres variantes:
    - DistilBERT (0.87): A pesar de ser una versión más ligera y reducida, mejora el rendimiento de los embeddings estáticos, demostrando eficiencia.
    - XLM-RoBERTa (0.89): Es un modelo multilingüe que muestra una gran robustez, acercándose al mejor resultado.

- BERT (0.90): Se posiciona como el mejor modelo de todos los evaluados, ya que está pensado específicamente para el inglés.

5.2 Z3: Transferencia entre Lenguas (dataset en castellano)

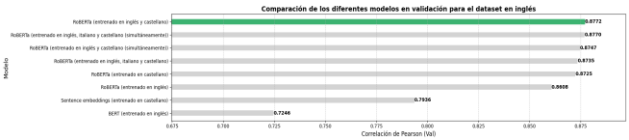

En cuanto al análisis de los modelos para el dataset en castellano, se pueden realizar las siguientes observaciones:

- El modelo BERT (específico para el inglés, entrenado con datos en inglés), que es el que mejores resultados obtiene para el dataset en inglés, obtiene malos resultados para el dataset en castellano, incluso peores que un modelo de *sentence embeddings* multilingüe entrenado de manera no supervisada con datos en castellano.
- Para el modelo xmlRoBERTa se han realizado varios experimentos:
    - Entrenado únicamente con datos en inglés: Este modelo, aunque haya sido únicamente entrenado en inglés, obtiene resultados mucho mejores que BERT para el dataset en castellano, ya que es un modelo multilingüe, por lo tanto, en el entrenamiento previo al ajuste fino, no habrá visto datos únicamente en inglés.
    - Entrenado únicamente con datos en castellano: Se obtienen, como es lógico, resultados algo mejores que con el ajuste fino con datos en inglés.
    - Entrenado secuencialmente con datos en inglés y castellano: En este caso se obtienen mejores resultados al entrenarlo en ambos idiomas que entrenándolo sólo en castellano, lo que confirma que la transferencia entre lenguas es útil y que el modelo aprende a aplicar y aprovechar conocimientos entre diferentes idiomas. Cabe destacar que en este caso ambos idiomas tienen prácticamente el mismo vocabulario, por lo que es más sencillo establecer esta relación entre lenguas.
    - Entrenado secuencialmente con datos en inglés, italiano y castellano: Como se puede ver, en este caso el entrenamiento en más idiomas ha hecho que disminuya el rendimiento en castellano. Puede que esto se deba a que el modelo ha aprendido algo sobre el nuevo idioma que ha "perjudicado" a la hora de evaluarlo en castellano, arrojando peores resultados.
    - Entrenado simultáneamente: Como se puede observar en el caso de juntar dos datasets el resultado obtenido es peor para los modelos entrenados de manera simultánea con todos los datos que al entrenarlos de manera secuencial, sin embargo con tres datasets es al revés. Dado que los entrenamientos son más sencillos y cortos de manera secuencial y que no asegura obtener mejores resultados, se puede concluir que es mejor la forma de entrenamiento secuencial que la simultánea.

6 Resultados para el conjunto de test

- Para el dataset en inglés:

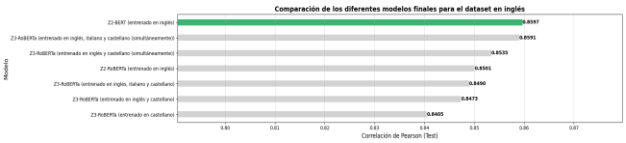

- Para el dataset en castellano:

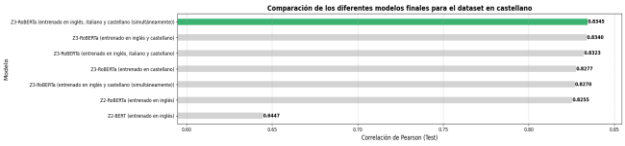

Como se puede observar los resultados para los conjuntos de test son algo peores que para los conjuntos de validación, como es de esperar ya que los hiperparámetros escogidos son los mejores para los conjuntos de validación. Aún así, estos resultados confirman lo comentado anteriormente para las hipótesis planteadas.

7 Conclusiones

De los experimentos realizados durante este proyecto se pueden extraer las siguientes conclusiones.

7.1 Superioridad de las Arquitecturas Cross-Encoder

Para tareas que requieren la máxima precisión en la evaluación de la similitud semántica, las arquitecturas Cross-Encoder son la mejor opción, gracias a su capacidad de modelar interacciones contextuales entre frases.

7.2 Eficacia de la Transferencia entre Lenguas (de manera secuencial)

El ajuste secuencial ha demostrado ser una estrategia muy eficiente para aprovechar los recursos lingüísticos existentes en idiomas de alto recurso (como el inglés) y transferir ese conocimiento a idiomas de más bajo recurso (como el castellano), optimizando el rendimiento y minimizando la necesidad de grandes datasets en lenguas poco frecuentes.

7.3 Importancia del Modelo Utilizado

Se ha podido observar que la arquitectura tomada como base es importante, ya que al tomar un modelo BERT, hecho para el inglés y entrenado con datos en inglés, se han obtenido muy malos resultados. Sin embargo, un modelo multilingüe como xmlRoBERTa, aunque haya sido entrenado únicamente con datos en inglés, ha sido capaz de arrojar buenos resultados también para el castellano.

8 Referencias

Mikolov, T., Yih, W., & Zweig, G. (2013). Linguistic Regularities in Continuous Space Word Representations. In Proceedings of NAACL-HLT.

Hinton, G. E. (1984). Distributed Representations. Technical Report, Carnegie Mellon University.

Iyyer, M., Manjunatha, V., Boyd-Graber, J., & Daumé III, H. (2015). Deep Unordered Composition Rivals Syntactic Methods for Text Classification. In Proceedings of the 53rd Annual Meeting of the Association for Computational Linguistics (ACL).

Levy, O., & Goldberg, Y. (2014). Dependency-Based Word Embeddings. In Proceedings of the 52nd Annual Meeting of the Association for Computational Linguistics.

Jurafsky, D., & Martin, J. H. (2025). Speech and Language Processing. (3rd ed. draft).

Dong, L., & Lapata, M. (2018). Coarse-to-Fine Decoding for Neural Semantic Parsing. In Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics.

9 Enlace al Código

https://colab.research.google.com/drive/17vwZlXgG6rFUG21PSwaANnpnq_OTbpT1?usp=sharing